

zero11



Politecnico  
di Torino

# Analisi del comportamento dei clienti di un e-commerce per prevedere le intenzioni d'acquisto

---


Candidato: **Simone Sinagra**

Relatore: **Luigi De Russis**

Tutor aziendale: **Michele Sonnessa**

# E-commerce e Customer eXperience (CX)

- Record del fatturato pari a 48.5 miliardi di € nel 2019
- Compound Annual Growth Rate del 25.5% nel periodo 2004-2019
- Entrata nel mercato digitale di 10.467 nuove imprese nel 2020



Fonte dati: Casaleggio Associati - Report 2021

**Customer eXperience:** esperienza complessiva dei clienti che si relazionano con l'azienda, percorrendo il cosiddetto **Customer Journey**

# Come migliorare la CX?

## Utilizzo di **contenuti dinamici**

Per poter offrire una CX più rilevante si possono mostrare contenuti che si adattano dinamicamente in base al cliente:

- Azioni compiute dal cliente durante la visita al sito
- Caratteristiche demografiche del cliente o del dispositivo utilizzato
- Interazioni passate del cliente con il sito

# Big Data


- Strumenti di monitoraggio raccolgono i dati delle azioni dei clienti dell'e-commerce
- Aumento della potenza di calcolo e dello spazio di archiviazione




Analisi efficiente di grandi volumi di dati per poter estrarre informazioni che aggiungono valore al business aziendale

# Obiettivo della Tesi

Creare un modello predittivo che permetta di distinguere le visite dei clienti intenzionati ad acquistare dalle visite dei clienti che non effettuano alcun acquisto



# Processo di sviluppo




# Tecnologie utilizzate



**Python**

- Linguaggio non compilato: richiede un interprete Python che permetta di convertire il codice in bytecode
- Ben fornita di librerie per la manipolazione dei dati e degli algoritmi di machine learning (Pandas, Scikit-learn e Matplotlib)





**Neo4j**

- Database open source NoSQL a grafo
- Struttura a nodi e archi che rappresentano entità e relazioni
- Linguaggio di query (DDL, DML, DQL) Cypher

## Database a grafo

- + Flessibilità
- + Prestazioni eccellenti per strutture altamente connesse
- + Scalabilità orizzontale

# Extract, Transform, Load (ETL)



## Estrazione dei dati

- Richiesta HTTP delle visite del sito all'API Matomo
- Libreria Python Requests
- Formato JSON


## Preparazione dei dati

- Visualizzazione e manipolazione dei dati ottenuti
- Libreria Python Pandas
- DataFrame (struttura dati tabulare bidimensionale)

## Caricamento dei dati

- Collegamento alla base di dati Neo4j
- Community drivers di Neo4j (package Python neo4j)
- Base di dati a grafo

## Estrazione dei dati




I dati ottenuti, in formato JSON, rappresentano le visite dei clienti sul sito.

Una visita contiene 103 attributi, tra cui l'attributo “actionDetails”.

Ad ogni visita è associato un numero variabile di azioni che contengono un massimo di 36 attributi.

Le azioni possono essere di 7 tipi: action, search, event, ecommerceOrder, ecommerceAbandonedCart, outlink, download

# Preparazione dei dati



1. Riduzione della dimensionalità del DataFrame:
  - selezione degli attributi più importanti
  - filtraggio delle visite non rilevanti (es. visite senza azioni)
2. Classificazione delle pagine web associate alle azioni di una visita

## DataFrame delle visite

	# Righe	# Colonne	Memoria [MB]
DataFrame iniziale	30.184	103	~ 23.9
DataFrame finale	18.905	22	~ 21.4

## DataFrame delle azioni

	# Righe	# Colonne	Memoria [MB]
DataFrame iniziale	213.116	36	~ 58.5
DataFrame finale	200.440	14	~ 55.4


# Caricamento dei dati





Salvataggio a blocchi per ottenere prestazioni migliori in quanto si riutilizza una sola sessione per inserire un insieme di visite

👍 Tempi di inserimento brevi




👎 Elevata complessità della query cypher



Definizione di indici e vincoli di integrità alle chiavi primarie dei nodi



# Valutazione dell'algoritmo ETL



## Analisi descrittiva del dataset

Il dataset in analisi contiene i dati di navigazione dei clienti su un sito B2B

- 23 giugno 2021 - 23 agosto 2021
- 152.424 visite totali
- 76.290 visite autenticate
- 3.291 visite con acquisti

	Con acquisti	Senza acquisti	TOTALE
Autenticate	3.291	72.999	76.290
Non autenticate	0	76.134	76.134
TOTALE	3.291	149.133	152.424

# Lunghezza delle visite (numero di azioni)







Diagramma a scatola e baffi della distribuzione dei valori di lunghezza delle visite





# Distribuzioni delle variabili indipendenti (esogena)

Impatto sulla variabile dipendente (endogena)



- Visite senza acquisti
- Visite con acquisti



# Pre-processing

- Filtraggio
- Feature Engineering
- Feature Selection
- Gestione dei valori mancanti
- Gestione delle variabili categoriche

	Dataset iniziale	Dataset finale
Visite totali (A)	152.424	29.157
Visite con acquisti (B)	3.291	2.010


rapporto % tra le visite con acquisti e le visite totali (B/A)

2,16%

6,89%

# Modello di classificazione Random Forest

Tecnica di apprendimento d'insieme



Accuratezza maggiore degli alberi decisionali

Robustezza al rumore ed eventuali outliers

Efficienza nella generazione del modello

Scalabilità del training set e del numero di attributi



Scarsa interpretabilità

Non incrementabile

# Risultati del modello di classificazione

I risultati sono stati ottenuti utilizzando il 75% di dati per il train e 25% di dati per il test



$$\text{Accuratezza} = \frac{TP + TN}{TP + TN + FP + FN} = 95,78\%$$

$$F_1 = 2 \cdot \frac{\text{Precisione} \cdot \text{Richiamo}}{\text{Precisione} + \text{Richiamo}} = 61,88\%$$

$$\text{Precisione} = \frac{TP}{TP + FP} \quad \text{Richiamo} = \frac{TP}{TP + FN}$$

# Valutazioni del modello di classificazione



Classificazione di una visita dopo un numero predefinito di azioni eseguite

Accuratezza del modello

~50% delle visite dei compratori (classe di minoranza) è classificato correttamente



Necessità di dover attendere un numero predefinito di azioni eseguite per poter classificare una visita

## Sviluppi futuri

- Utilizzo e valutazione dell'efficacia del modello predittivo
- Miglioramento dell'algoritmo di classificazione aggiungendo nuove feature per il training
- Sviluppo di altri algoritmi per classificare la visita ad ogni azione del cliente

**GRAZIE PER L'ATTENZIONE!**



**DOMANDE**